



# 数字图像处理

## 第七章 小波变换和其他图像变换




赵荣昌 (byrons.zhao@gmail.com)


中南大学计算机学院

# 一、背景

## ➤ 正交投影



$$\vec{V} = C_1\vec{v}_x + C_2\vec{v}_y$$



$$\vec{V} = C_1\vec{v}_x + C_2\vec{v}_y + C_3\vec{v}_z$$

# 一、背景

## ➤ 信号内积与内积空间

### 内积

$$\begin{aligned} \langle u, v \rangle &= \langle u, v \rangle^* \\ \langle u + v, w \rangle &= \langle u, w \rangle + \langle v, w \rangle \\ \langle \alpha u, v \rangle &= \alpha \langle u, v \rangle \\ \langle v, v \rangle &\geq 0 \text{ and } \langle v, v \rangle = 0 \text{ only } v = 0 \end{aligned}$$

### 内积空间

数域上的抽象向量空间，与内积函数共同将向量空间中的两个向量映射为属于的一个标量。

✓ 假设 $u(t)$ 和 $v(t)$ 是定义在 $(t_1, t_2)$ 区间的函数，其内积为

$$\langle u(t), v(t) \rangle = \int_{t_1}^{t_2} u(t)v(t) dt$$

✓ 向量 $z$ 的范数

$$\|z\| = \sqrt{\langle z, z \rangle}$$

✓ 两个向量间的角度

$$\theta = \frac{\langle z_1, z_2 \rangle}{\|z_1\| \|z_2\|}$$

# 一、背景

## ➤ 信号内积与内积空间

✓ 设有  $\mathbf{u}$  和  $\mathbf{v}$  是  $N \times 1$  的列向量，具有如下标量内积的实数域  $\mathbf{R}$  上的欧式空间  $\mathbf{R}^N$

$$\langle \mathbf{u}, \mathbf{v} \rangle = \mathbf{u}^T \mathbf{v} = u_0 v_0 + u_1 v_1 + \dots u_{N-1} v_{N-1} = \sum_{i=0}^{N-1} u_i v_i$$

✓ 设有  $\mathbf{u}$  和  $\mathbf{v}$  是  $N \times 1$  的复值列向量，\*表示复共轭运算，有内积函数的复数域  $\mathbf{C}$  上的酉空间  $\mathbf{C}^N$

$$\langle \mathbf{u}, \mathbf{v} \rangle = \mathbf{u}^{*T} \mathbf{v} = \sum_{i=0}^{N-1} u_i^* v_i = \langle \mathbf{v}, \mathbf{u} \rangle^*$$

✓ 内积空间  $\mathbf{C}([a, b])$ ，其中向量是区间  $a \ll x \ll b$  上连续函数，内积函数是积分内积

$$\langle f(x), g(x) \rangle = \int_a^b f^*(x) g(x) dx$$

# 一、背景

## ➤ 信号正交

定义在 $(t_1, t_2)$ 区间的 $u(t)$ 和 $v(t)$ 满足

$$\langle u(t), v(t) \rangle = \int_{t_1}^{t_2} u(t)v(t) dt = 0 \quad (\text{两函数的内积为0})$$

则称 $u(t)$ 和 $v(t)$ 在区间 $(t_1, t_2)$ 内正交。

## ➤ 正交函数集:

若 $n$ 个函数 $u_1(t), u_2(t), \dots, u_n(t)$ 构成一个函数集, 这些函数在区间 $(t_1, t_2)$ 内满足

$$\int_{t_1}^{t_2} u_i(t)u_j(t) dt = \begin{cases} 0, & i \neq j \\ K_i \neq 0, & i = j \end{cases}$$

则称此函数集为在区间 $(t_1, t_2)$ 的**正交函数集/正交向量集**。

$$\begin{aligned} \langle u, v \rangle &= \langle u, v \rangle^* \\ \langle u + v, w \rangle &= \langle u, w \rangle + \langle v, w \rangle \\ \langle \alpha u, v \rangle &= \alpha \langle u, v \rangle \\ \langle v, v \rangle &\geq 0 \text{ and } \langle v, v \rangle = 0 \text{ only } v = 0 \end{aligned}$$

# 一、背景

## ➤ 向量正交

设有  $\mathbf{u}$  和  $\mathbf{v}$  是  $N \times 1$  的列向量，具有如下内积的实数域  $\mathbf{R}$  上的欧氏空间  $\mathbf{R}^N$

$$\langle \mathbf{u}, \mathbf{v} \rangle = \mathbf{u}^T \mathbf{v} = u_0 v_0 + u_1 v_1 + \dots u_{N-1} v_{N-1} = \sum_{i=0}^{N-1} u_i v_i = 0$$

## ➤ 正交基

- 如果  $\langle \mathbf{u}, \mathbf{v} \rangle = 0$ , 称  $\mathbf{u}$  和  $\mathbf{v}$  是正交的
- 若果非零向量  $\mathbf{w}_0, \mathbf{w}_1, \mathbf{w}_2, \dots$  是互相两两正交, 即  $\langle \mathbf{w}_i, \mathbf{w}_j \rangle = 0, i \neq j$ , 它们是内积空间的正交基。

$$\langle \mathbf{w}_i, \mathbf{w}_j \rangle = \delta_{ij} = \begin{cases} 0, & i \neq j \\ 1, & i = j \end{cases}$$

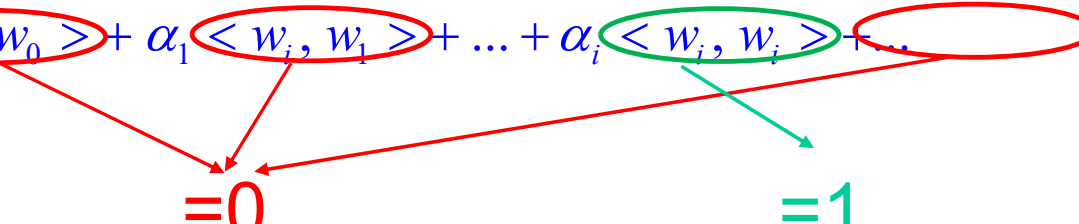
# 一、背景

## ➤ 向量的正交分解

$$z = \alpha_0 w_0 + \alpha_1 w_1 + \alpha_2 w_2 + \dots$$

它和基向量 $w_i$ 的内积

$$\begin{aligned} \langle w_i, z \rangle &= \langle w_i, \alpha_0 w_0 + \alpha_1 w_1 + \alpha_2 w_2 + \dots \rangle \\ &= \alpha_0 \langle w_i, w_0 \rangle + \alpha_1 \langle w_i, w_1 \rangle + \dots + \alpha_i \langle w_i, w_i \rangle + \dots \end{aligned}$$



即

$$\alpha_i = \frac{\langle w_i, z \rangle}{\langle w_i, w_i \rangle}$$

所以系数

$$= \frac{\int_{t_1}^{t_2} w_i(t) z(t) dt}{\int_{t_1}^{t_2} w_i^2(t) dt} = \frac{1}{K_i} \int_{t_1}^{t_2} w_i(t) z(t) dt$$

# 一、背景

## ➤ 向量的正交分解

向量  $z(t)$  或者  $z$  可分解为无穷多项正交基之和

$$z(t) = \sum_{i=1}^{\infty} \alpha_i w_i(t)$$

$$\alpha_i = \frac{1}{K_i} \int_{t_1}^{t_2} z(t) w_i(t) dt = \langle z, w_i \rangle$$

## ➤ 最简单的正交函数集是什么？三角函数！！



# 一、背景

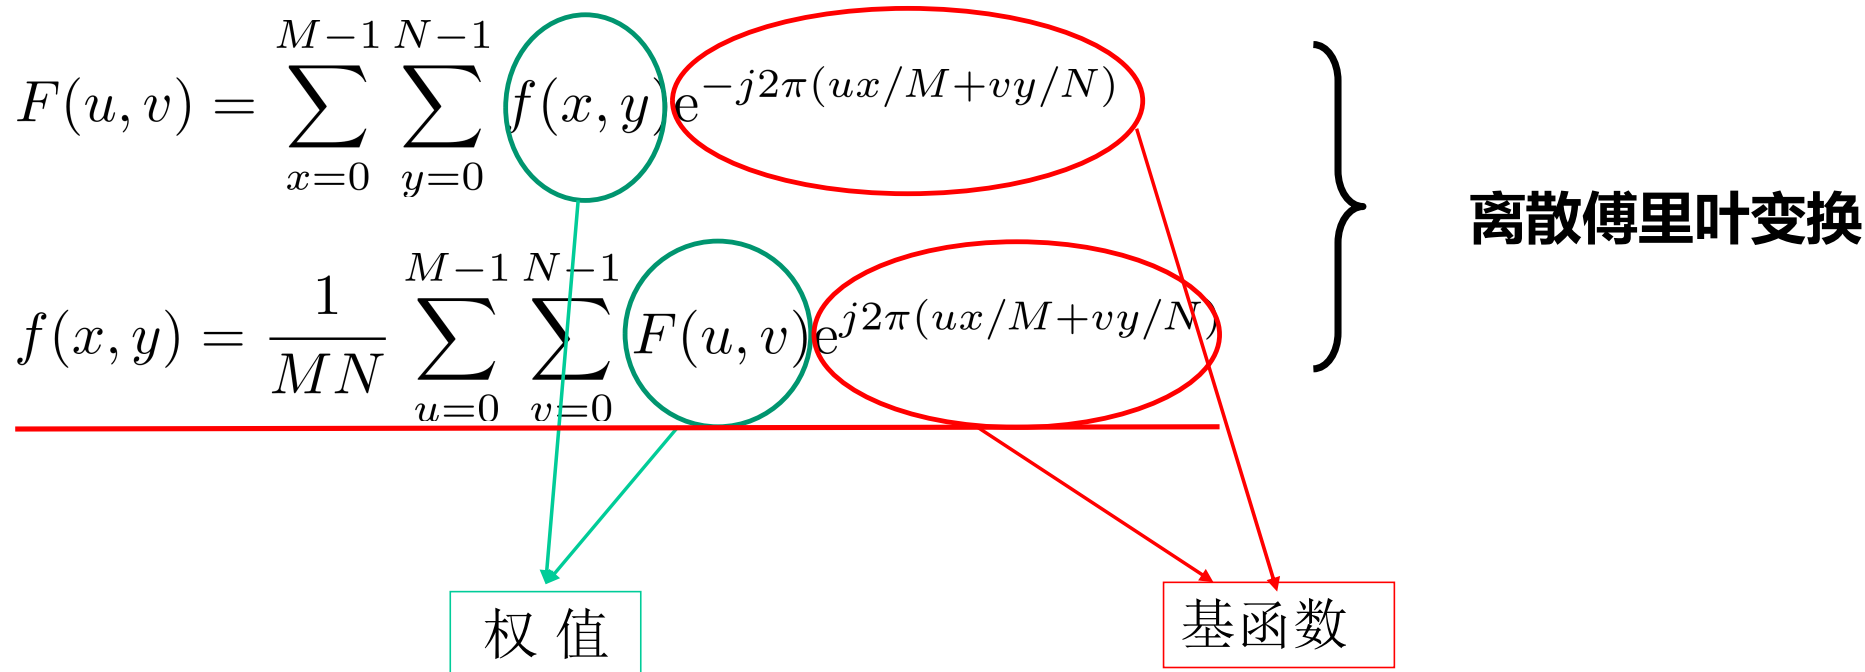
## ➤ Discrete Fourier Transform, DFT

$$F(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) e^{-j2\pi(ux/M + vy/N)}$$

$$f(x, y) = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} F(u, v) e^{j2\pi(ux/M + vy/N)}$$

离散傅里叶变换

权 值
基函数



# 一、背景

## ➤ 向量的正交分解

向量  $z(t)$  或者  $z$  可分解为无穷多项正交基之和

$$z(t) = \sum_{i=1}^{\infty} \alpha_i w_i(t)$$

$$\alpha_i = \frac{1}{K_i} \int_{t_1}^{t_2} z(t) w_i(t) dt = \langle z, w_i \rangle$$

- 基函数决定变换的性质和作用，系数是变换域参数
- 三角函数是最好的基函数吗？有没有其他基函数？

# 一、背景

## ➤ 相关的意义

- ✓ 如果两个连续函数 $f(x)$ 、 $g(x)$ ,它们的**相关**定义为

$$f \diamond g(\Delta x) = \int_{-\infty}^{\infty} f^*(x)g(x + \Delta x)dx = \langle f(x), g(x + \Delta x) \rangle$$

滑动内积，度量的是两个函数的**相似性**


- ✓ 若 $\Delta x=0$ , 则  $f \diamond g(0) = \int_{-\infty}^{\infty} f^*(x)g(x)dx = \langle f(x), g(x) \rangle$

- ✓ 信号正交分解  $\alpha_i = \frac{1}{K_i} \int_{t_1}^{t_2} z(t)w_i(t)dt = \langle z, w_i \rangle$

- ✓ 傅里叶变换  $f(x, y) = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} F(u, v)e^{j2\pi(ux/M+vy/N)}$

## 二、基于矩阵的变换

### ➤ 变换



$$T(u) = \langle s(x, u), f(x) \rangle$$



## 二、基于矩阵的变换

### ➤ 变换

矩阵形式

$$T(u) = \sum_{x=0}^{N-1} f(x)r(x,u)$$

$$f(x) = \sum_{u=0}^{N-1} T(u)s(x,u)$$

$$f = \begin{bmatrix} f(0) \\ f(1) \\ \vdots \\ f(N-1) \end{bmatrix} = \begin{bmatrix} f_0 \\ f_1 \\ \vdots \\ f_{N-1} \end{bmatrix} \quad t = \begin{bmatrix} T(0) \\ T(1) \\ \vdots \\ T(N-1) \end{bmatrix} = \begin{bmatrix} t_0 \\ t_1 \\ \vdots \\ t_{N-1} \end{bmatrix}$$

$$s_u = \begin{bmatrix} s(0,u) \\ s(1,u) \\ \vdots \\ s(N-1,u) \end{bmatrix} = \begin{bmatrix} s_{u,0} \\ s_{u,1} \\ \vdots \\ s_{u,N-1} \end{bmatrix}$$

$$s = \begin{bmatrix} s(0,0) & s(0,1) & \dots & s(0,N-1) \\ s(1,0) & s(1,1) & \dots & s(1,N-1) \\ \vdots & \vdots & \ddots & \vdots \\ s(N-1,0) & s(N-1,1) & \dots & s(N-1,N-1) \end{bmatrix} = \begin{bmatrix} s_0^T \\ s_1^T \\ \vdots \\ s_{N-1}^T \end{bmatrix} \quad T(u) = \langle s_u, f \rangle, \quad u = 0, 1, \dots, N-1$$



## 二、基于矩阵的变换

### ➤ 变换

定义变换矩阵  $A = \begin{bmatrix} s_0^T \\ s_1^T \\ \vdots \\ s_{N-1}^T \end{bmatrix} = [s_0, s_1, \dots, s_{N-1}]^T$

代入

$$t = \begin{bmatrix} T(0) \\ T(1) \\ \vdots \\ T(N-1) \end{bmatrix} = \begin{bmatrix} \langle s_0, f \rangle \\ \langle s_1, f \rangle \\ \vdots \\ \langle s_{N-1}, f \rangle \end{bmatrix} = \begin{bmatrix} s_{0,0}f_0 + s_{1,0}f_1 + \dots + s_{N-1,0}f_{N-1} \\ s_{0,1}f_0 + s_{1,1}f_1 + \dots + s_{N-1,1}f_{N-1} \\ \vdots \\ s_{0,N-1}f_0 + s_{1,N-1}f_1 + \dots + s_{N-1,N-1}f_{N-1} \end{bmatrix}$$

$$= \begin{bmatrix} s_{0,0} & s_{1,0} & \dots & s_{N-1,0} \\ s_{0,1} & s_{1,1} & \dots & s_{N-1,1} \\ \vdots & \vdots & \ddots & \vdots \\ s_{0,N-1} & s_{1,N-1} & \dots & s_{N-1,N-1} \end{bmatrix} \begin{bmatrix} f_0 \\ f_1 \\ \vdots \\ f_{N-1} \end{bmatrix}$$

$$t = Af$$

## 二、基于矩阵的变换

### ➤ 变换

定义变换矩阵

$$A = \begin{bmatrix} s_0^T \\ s_1^T \\ \vdots \\ s_{N-1}^T \end{bmatrix} = [s_0, s_1, \dots, s_{N-1}]^T \quad AA^T = \begin{bmatrix} s_0^T \\ s_1^T \\ \vdots \\ s_{N-1}^T \end{bmatrix} [s_0, s_1, \dots, s_{N-1}]^T = I$$

$$t = Af \quad \longrightarrow \quad f = A^T t$$

正交变换：变换矩阵 $A$ 的 $N$ 个基向量是实的和正交的

$$\langle s_i, s_j \rangle = s_i^T s_j = \delta_{ij} = \begin{cases} 0 & i \neq j \\ 1 & i = j \end{cases}$$

## 二、基于矩阵的变换

### ➤ 二维图像

$$T(u, v) = \sum_{x=0}^{N-1} \sum_{y=0}^{N-1} f(x, y) r(x, y, u, v)$$
$$f(x, y) = \sum_{u=0}^{N-1} \sum_{v=0}^{N-1} T(u, v) s(x, y, u, v)$$

若正变换核是可分离、对称的，且实的和规范正交的

$$r(x, y, u, v) = r_1(x, u) r_2(y, v) = r_1(x, u) r_1(y, v)$$

$T = AFA^T$   $F$ 是包括  $f(x, y)$  元素的  $N \times N$  矩阵， $T$  是其变换

$F = A^T T A$   $A$  是方阵



## 二、基于矩阵的变换

### ➤ 举个例子

基向量  $s_0 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad s_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$

$$A = [s_0 \ s_1]^T = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

规范正交

$$\left\{ \begin{array}{l} \langle s_0, s_1 \rangle = s_0^T s_1 = \frac{1}{2} \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 0 \\ \langle s_1, s_0 \rangle = s_1^T s_0 = \frac{1}{2} \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = 0 \\ \langle s_0, s_0 \rangle = s_0^T s_0 = \frac{1}{2} \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = 1 \\ \langle s_1, s_1 \rangle = s_1^T s_1 = \frac{1}{2} \begin{bmatrix} 1 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 1 \end{array} \right.$$

$$T = AFA^T = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} F \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}^T$$

$$F = A^T T A = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}^T T \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

## 二、基于矩阵的变换

➤ 如果  $F$  是矩形阵列

$$T = A_M F A_N^T$$

$$F = A_M^T T A_N$$

$F$ ,  $A_M$  和  $A_N$  大小分别为  $M \times N$ ,  $M \times M$  和  $N \times N$

例题7.3  $F = \begin{bmatrix} 5 & 100 & 44 \\ 6 & 103 & 40 \end{bmatrix}$

$$T = A_2 F A_3^T$$

$$= \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 5 & 100 & 44 \\ 6 & 103 & 40 \end{bmatrix} \frac{1}{\sqrt{3}} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 0.366 & -1.366 \\ 1 & -1.366 & 0.366 \end{bmatrix}$$

## 二、基于矩阵的变换

➤ 如果  $A$  复规范正交向量

$$\langle s_i, s_j \rangle = \langle s_j, s_i \rangle^* = s_i^{*T} s_j = \delta_{ij} = \begin{cases} 0 & i \neq j \\ 1 & i = j \end{cases}$$

$$T = AFA^T$$

$$F = A^{*T}TA^*$$

酉矩阵  
酉变换

$$A^{*T}A = AA^{*T} = A^*A^T = A^TA^* = I$$

$$t = Af$$

$$f = A^{*T}t$$

✓ 内积函数的复数域  $\mathbf{C}$  的酉空间  $\mathbf{C}^N$ :

$$\langle u, v \rangle = u^{*T}v = \sum_{i=0}^{N-1} u_i^* v_i = \langle v, u \rangle^*$$

$$A = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 & 1 & 1 \\ 1 & -0.5 - j0.866 & -0.5 + j0.866 \\ 1 & -0.5 + j0.866 & -0.5 - j0.866 \end{bmatrix}$$

\*表示复共轭运算， $u$  和  $v$  是  $N \times 1$  复值列向量

## 二、基于矩阵的变换

➤ 如果  $A$  是双规范正交基函数

$$\langle \tilde{s}_i, s_j \rangle = \delta_{ij} = \begin{cases} 0 & i \neq j \\ 1 & i = j \end{cases}$$

$\tilde{s}$  是对偶展开函数， $s$  是双规范正交的。

$$T = \tilde{A} F \tilde{A}^T$$

$$F = A^T T A$$

$$t = \tilde{A} f$$

$$f = A^T t$$

$$A = \begin{bmatrix} 0.5 & 0.5 & 0.5 & 0.5 \\ -1 & -1 & 1 & 1 \\ -0.5303 & 0.5303 & -0.1768 & 0.1768 \\ -0.1768 & 0.1768 & -0.5303 & 0.5303 \end{bmatrix}$$

$$\tilde{A} = \begin{bmatrix} 0.5 & 0.5 & 0.5 & 0.5 \\ -0.25 & -0.25 & 0.25 & 0.25 \\ -1.0607 & 1.0607 & 0.3536 & -0.3536 \\ 0.3536 & -0.3536 & -1.0607 & 1.0607 \end{bmatrix}$$

## 二、基于矩阵的变换

### ➤ 傅里叶级数和离散傅里叶变换

周期为T的连续函数，规范正交基函数

$$s_u(x) = \frac{1}{\sqrt{T}} e^{j2\pi ux/T}, \quad u = 0, \pm 1, \pm 2, \dots$$

$$f(x) = \sum_{u=-\infty}^{\infty} \alpha_u \left[ \frac{1}{\sqrt{T}} e^{j2\pi ux/T} \right] = \frac{1}{\sqrt{T}} \sum_{u=-\infty}^{\infty} \alpha_u [e^{j2\pi ux/T}]$$

$$\alpha_u = \langle s_u(x), f(x) \rangle = \int_{-T/2}^{T/2} \left[ \frac{1}{\sqrt{T}} e^{j2\pi ux/T} \right]^* f(x) dx$$

## 二、基于矩阵的变换

### ➤ 傅里叶级数和离散傅里叶变换

离散复值基向量是内积空间 $\mathbf{C}^N$ 的规范正交基

$$s(x, u) = \frac{1}{\sqrt{N}} e^{j2\pi ux/N}, \quad u = 0, 1, 2, \dots, N-1$$

$$f(x) = \frac{1}{\sqrt{N}} \sum_{u=0}^{N-1} T(u) e^{j2\pi ux/N}$$

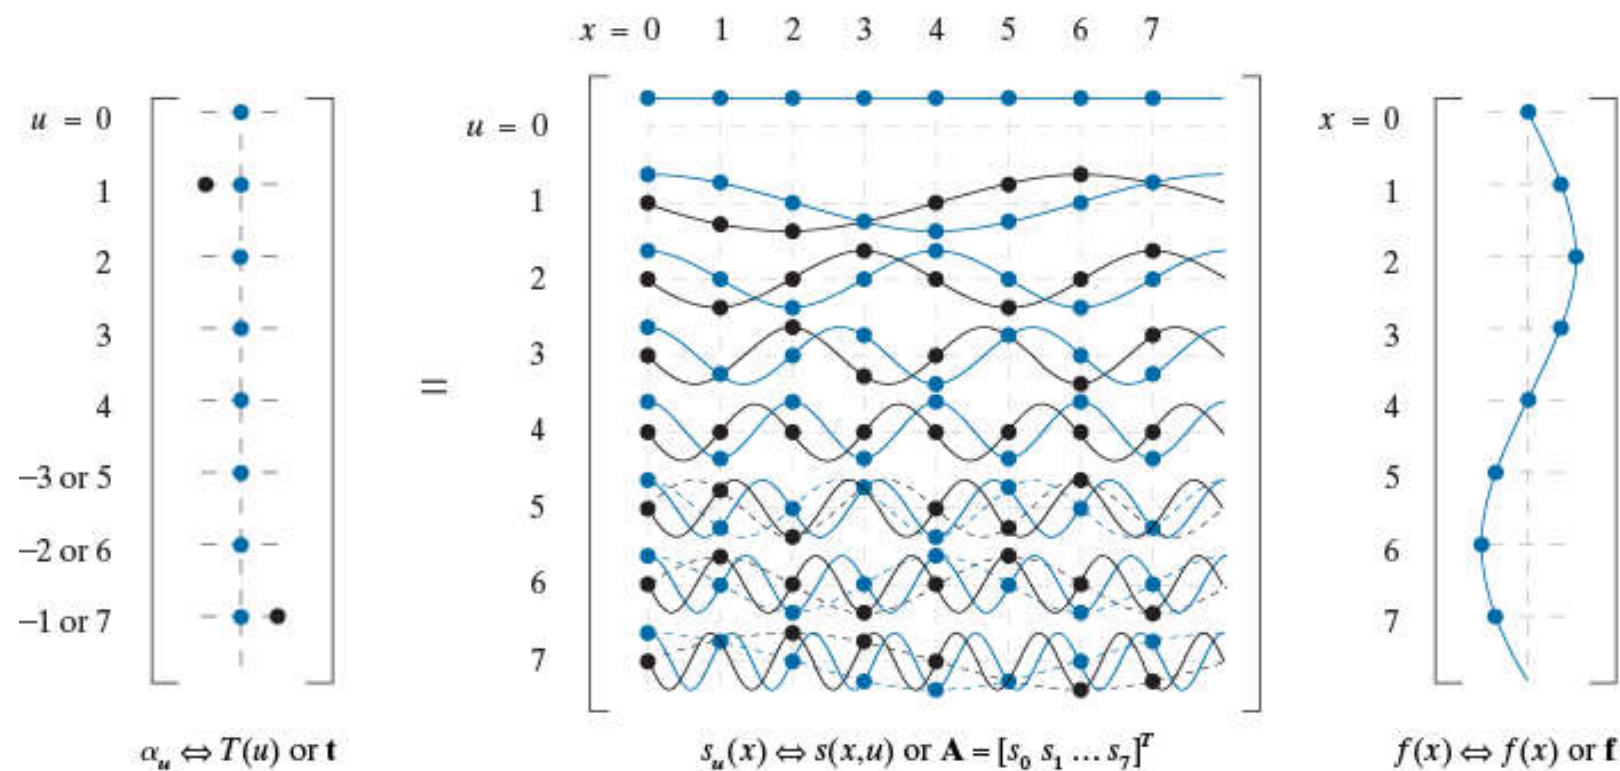
$$T(u) = \langle s(x, u), f(x) \rangle = \frac{1}{\sqrt{N}} \sum_{u=0}^{N-1} f(x) e^{-j2\pi ux/N}$$

## 二、基于矩阵的变换

### ➤ 傅里叶级数和离散傅里叶变换

$$t = Af$$

$$f = A^{-1}t$$



### 三、时间-频率平面的基函数

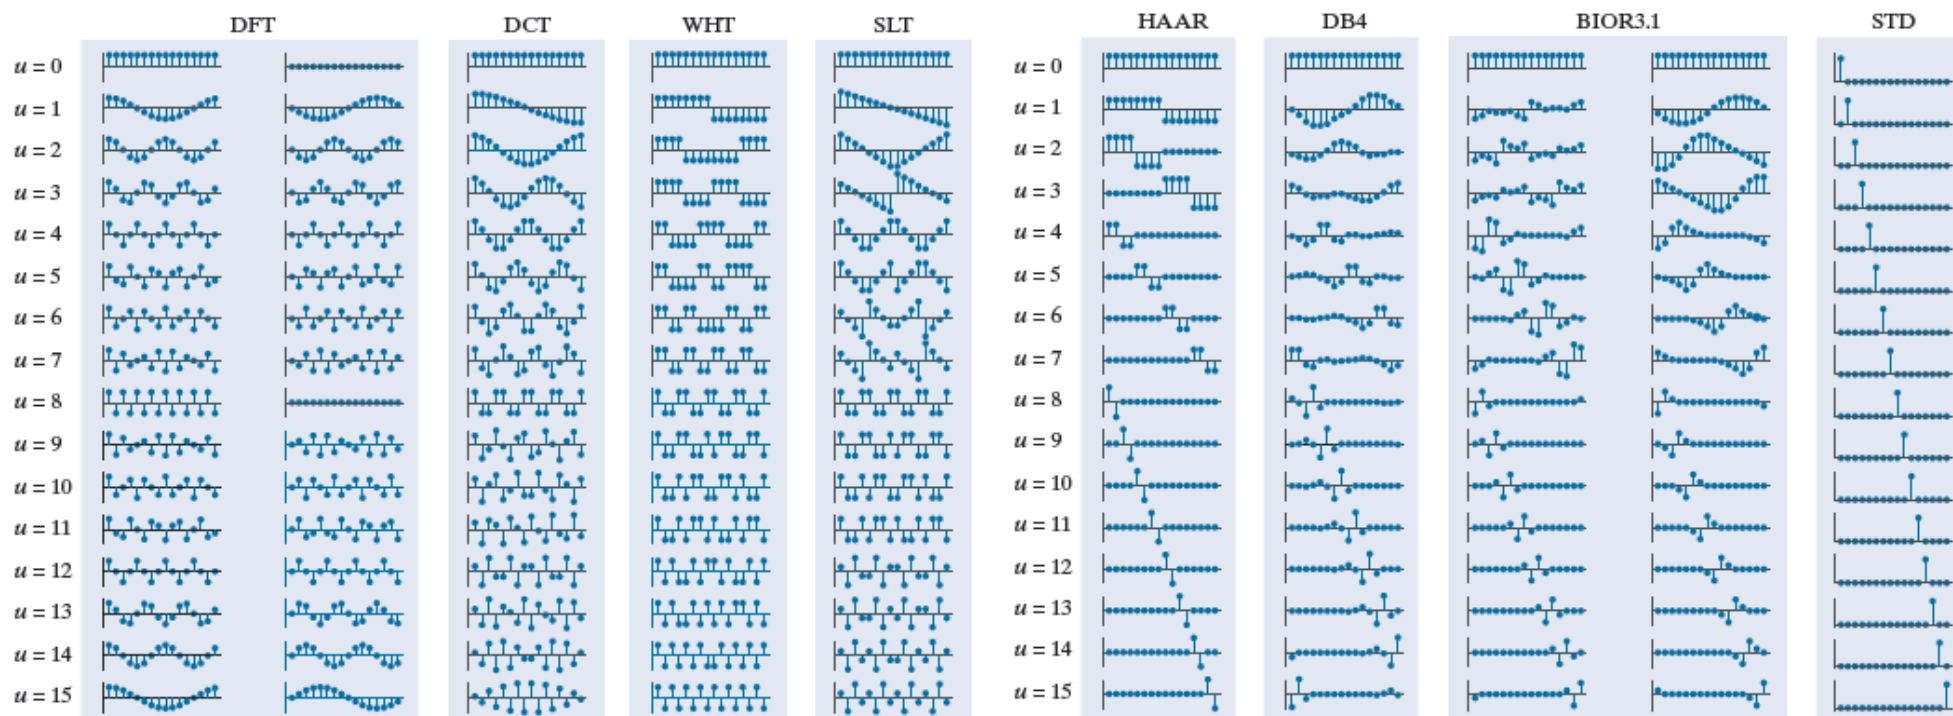
变换度量的是一个函数与所选基向量的相似程度

#### ➤ 基函数或基向量的选择

原则：正交、简单

$$f(x) = \frac{1}{\sqrt{N}} \sum_{u=0}^{N-1} T(u)s(x,u)$$

$$T(u) = \langle s(x,u), f(x) \rangle = s_u \diamond f(0)$$



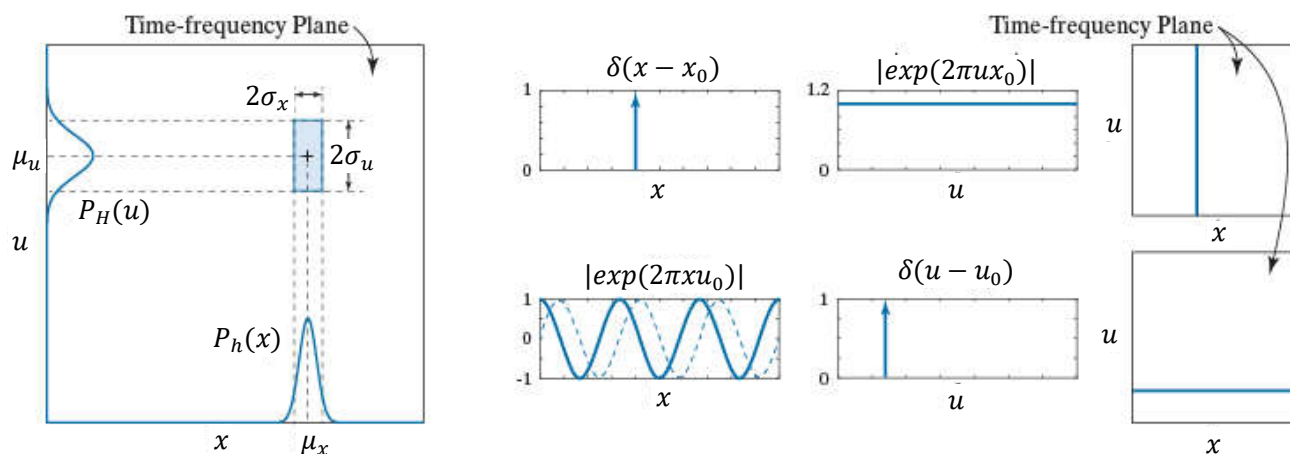


### 三、时间-频率平面的基函数

$$\begin{aligned}
 t &= Af & f &= A^T t \\
 T &= AFA^T \\
 F &= A^T TA
 \end{aligned}
 \quad
 A = \begin{bmatrix}
 s(0,0,u,v) & s(0,1,u,v) & \dots & s(0,N-1,u,v) \\
 s(1,0,u,v) & s(1,1,u,v) & \dots & s(1,N-1,u,v) \\
 \vdots & \vdots & \ddots & \vdots \\
 s(N-1,0,u,v) & s(N-1,1,u,v) & \dots & s(N-1,N-1,u,v)
 \end{bmatrix}$$

$F$ 是包括 $f(x,y)$ 元素的 $N \times N$ 矩阵， $T$ 是其变换结果

$A$ 是方阵，度量的是一个函数与所选基向量的相似程度



### 三、时间-频率平面的基函数

#### ➤ 基函数或基向量的选择

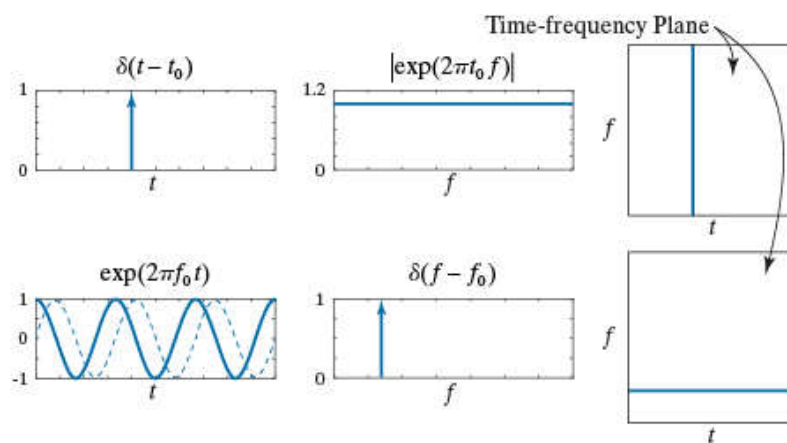

原则：正交、简单

变换度量的是一个函数与所选基向量的相似程度

$$f(x) = \frac{1}{\sqrt{N}} \sum_{u=0}^{N-1} T(u)s(x,u)$$

$$T(u) = \langle s(x,u), f(x) \rangle = s_u \diamond f(0)$$

$$T(u) = \langle s(x,u), f(x) \rangle = s_u \diamond f(0) = \sum_{x=0}^{N-1} s^*(x,u) f(x)$$



$$\sigma_x^2 \sigma_u^2 \geq \frac{1}{16\pi^2}$$

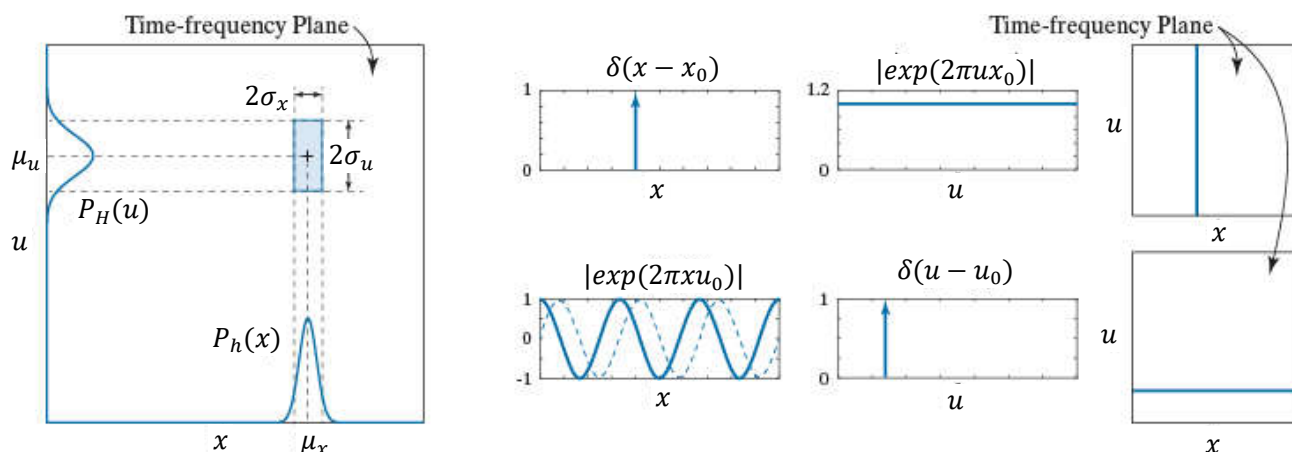
海森堡测不准原理



## 三、时间-频率平面的基函数

### ➤ 基函数或基向量的选择

原则：正交、简单



$$\sigma_t^2 \sigma_f^2 \geq \frac{1}{16\pi^2}$$

海森堡测不准原理

傅里叶变换：
$$F(u) = \sum_{x=0}^{M-1} f(x)e^{-j2\pi ux/M}, \quad u = 0, 1, 2, \dots, M-1$$

$$f(x) = \frac{1}{M} \sum_{u=0}^{M-1} F(u)e^{j2\pi ux/M}, \quad x = 0, 1, 2, \dots, M-1$$



### 三、时间-频率平面的基函数

变换度量的是一个函数与所选基向量的相似程度

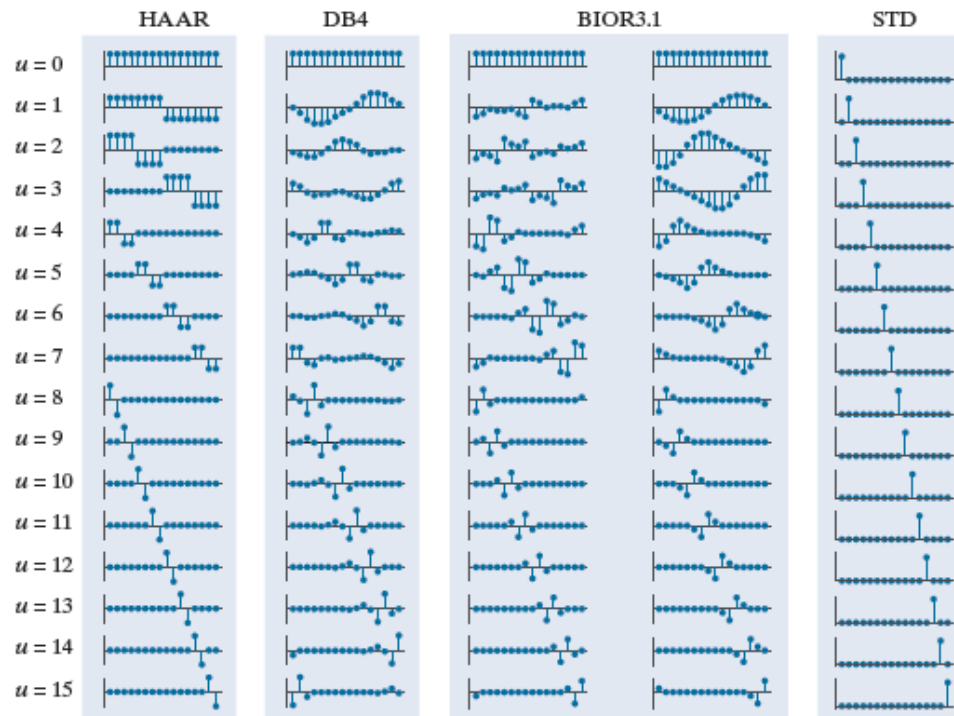
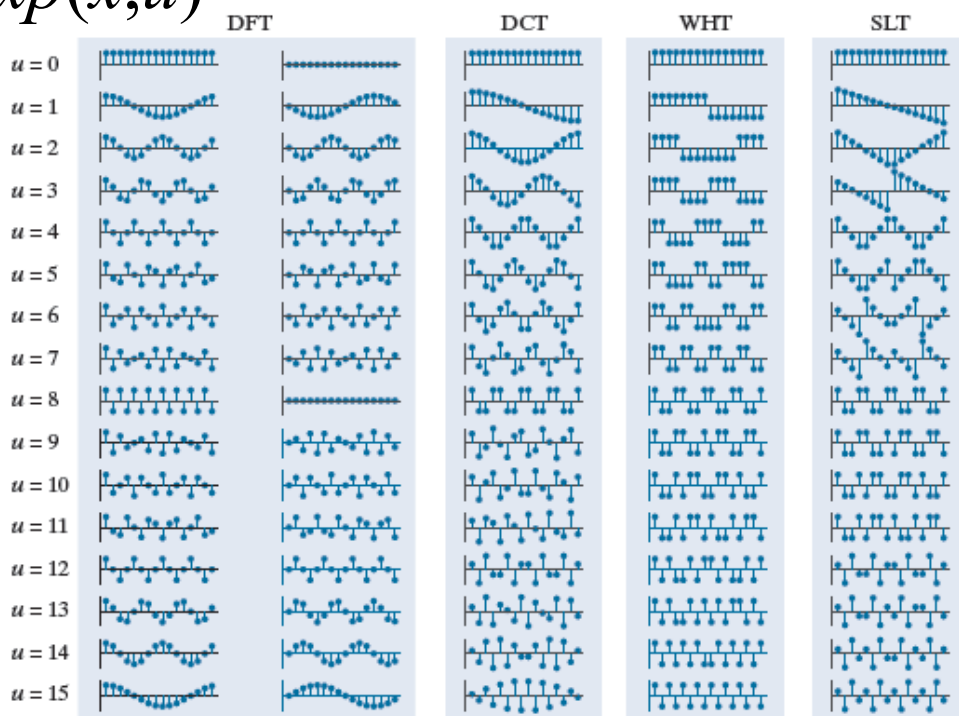
$$f(x) = \frac{1}{\sqrt{N}} \sum_{u=0}^{N-1} T(u)s(x,u)$$

$$T(u) = \langle s(x,u), f(x) \rangle = s_u \diamond f(0)$$

#### ➤ 基函数或基向量的选择

原则：正交、简单

$exp(x,u)$



$\delta(x,u)$

### 三、时间-频率平面的基函数

变换度量的是一个函数与所选基向量的相似程度

$$f(x) = \frac{1}{\sqrt{N}} \sum_{u=0}^{N-1} T(u)s(x,u)$$


$$T(u) = \langle s(x,u), f(x) \rangle = s_u \diamond f(0)$$

#### ➤ 基函数或基向量的选择



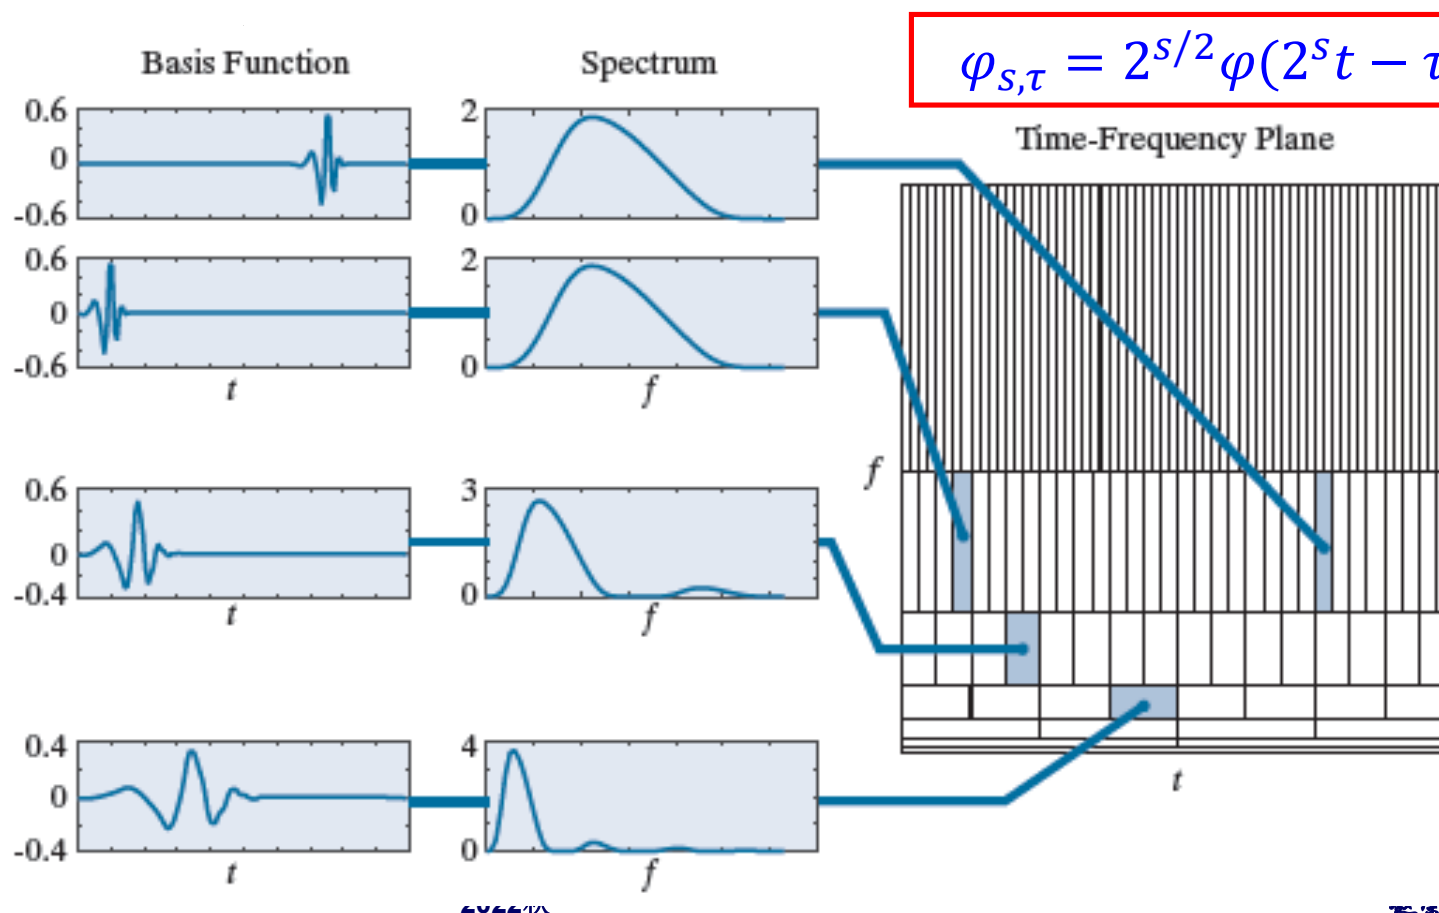
轮廓区域

细节区域



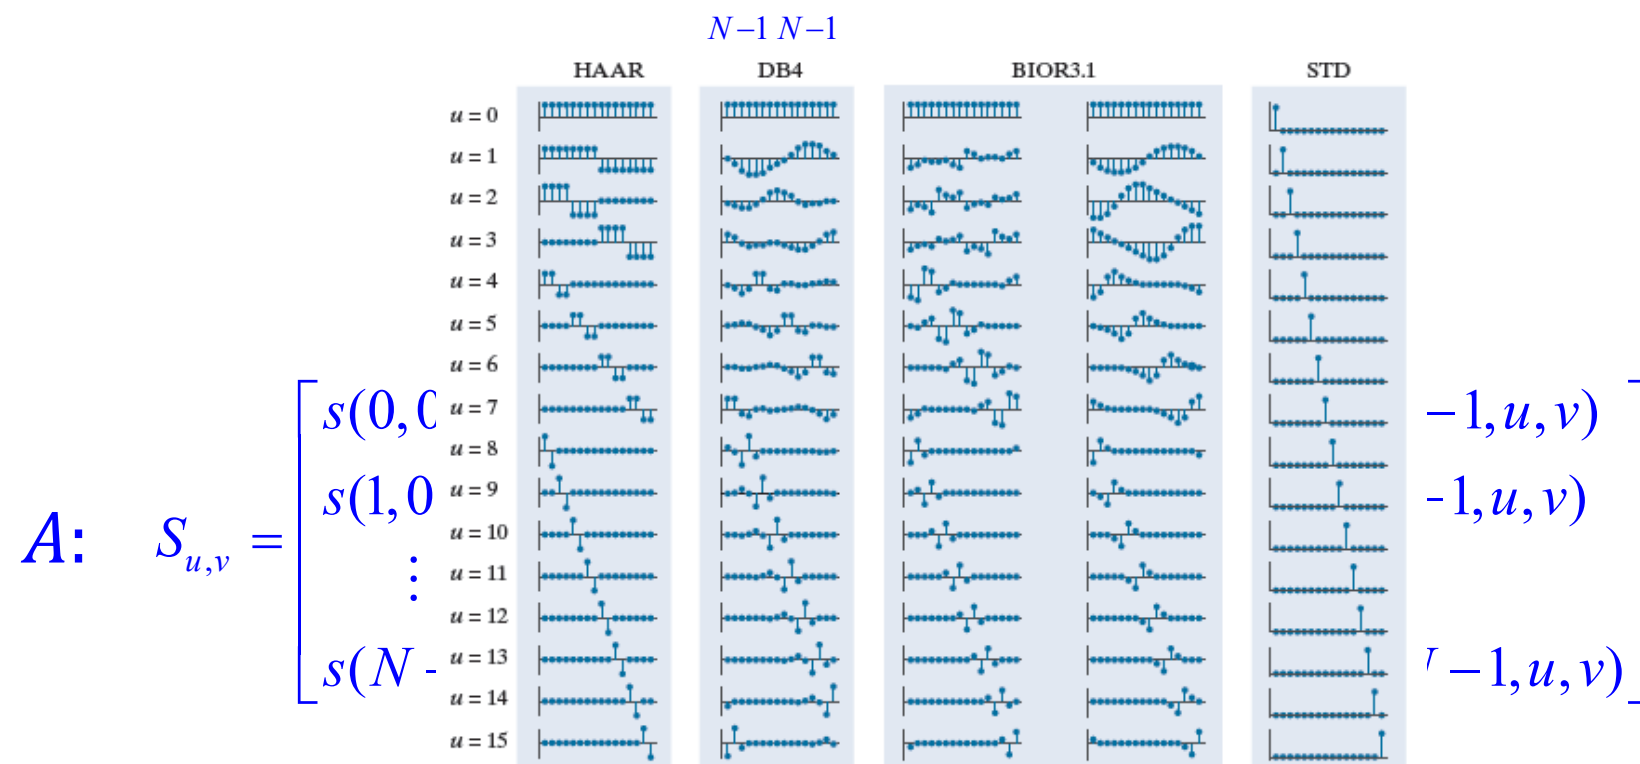
### 三、时间-频率平面的基函数

- 基函数或基向量的选择 每个基函数都有一个唯一的谱和时间位置表征。



## 四、基图像

### ➤ 基函数或基向量的选择



若 $s(x,y,u,v)$ 是实值、可分离和对称的

$$S_{u,v} = s_u s_v^T$$

基图像

## 四、基图像

### ➤ 标准基的基图像

基函数是 $N \times 1$ 的列向量，第 $n$ 个元素是1，其他元素是0

如果是 $8 \times 8$ 的二维标准基

$N \times N$ 的零矩阵，仅仅第 $u$ 行第 $v$ 列的元素为1.

$s_{0,0}$	$s_{0,1}$	...	...	$s_{0,N-1}$
$s_{1,0}$	$\ddots$			$\vdots$
$\vdots$				
			$\ddots$	
				$\vdots$
$s_{N-1,0}$	...		...	$s_{N-1,N-1}$

$$A = I$$

$$T = AFA^T = IFI^T = F$$

$\begin{matrix} \downarrow v \\ u \end{matrix}$	0	1	2	3	4	5	6	7
0								
1								
2								
3								
4								
5								
6								
7								




## 四、基图像

### ➤ 标准基的基图像

$N=8$ 时，离散傅里叶变换

$$s_{u,v} = e^{-j2\pi uv/8} = (e^{-j2\pi/8})^{uv} = \omega^{uv}$$

$$\frac{1}{\sqrt{8}} \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & \omega & -j & -j\omega & -1 & -\omega & j & j\omega \\ 1 & -j & -1 & j & 1 & -j & -1 & j \\ 1 & -j\omega & j & \omega & -1 & j\omega & -j & -\omega \\ 1 & -1 & 1 & -1 & 1 & -1 & 1 & -1 \\ 1 & -\omega & -j & j\omega & -1 & \omega & j & -j\omega \\ 1 & j & -1 & -j & 1 & j & -1 & -j \\ 1 & j\omega & j & -\omega & -1 & -j\omega & -j & \omega \end{bmatrix}$$



## 四、傅里叶相关的变换

### ➤ 离散哈特利变换

离散哈特利变换DHT反变换核

傅里叶变换是复值的，那不是复值的是什么呢？

$$s(x, u) = \frac{1}{\sqrt{N}} \text{cas}\left(\frac{2\pi ux}{N}\right) = \frac{1}{\sqrt{N}} \left[ \cos\left(\frac{2\pi ux}{N}\right) + \sin\left(\frac{2\pi ux}{N}\right) \right]$$

二维形式

$$s(x, y, u, v) = \left[ \frac{1}{\sqrt{N}} \text{cas}\left(\frac{2\pi ux}{N}\right) \right] \left[ \frac{1}{\sqrt{N}} \text{cas}\left(\frac{2\pi vy}{N}\right) \right]$$



变换矩阵 $A_{HY}$ ， 实的、正交的、对称的

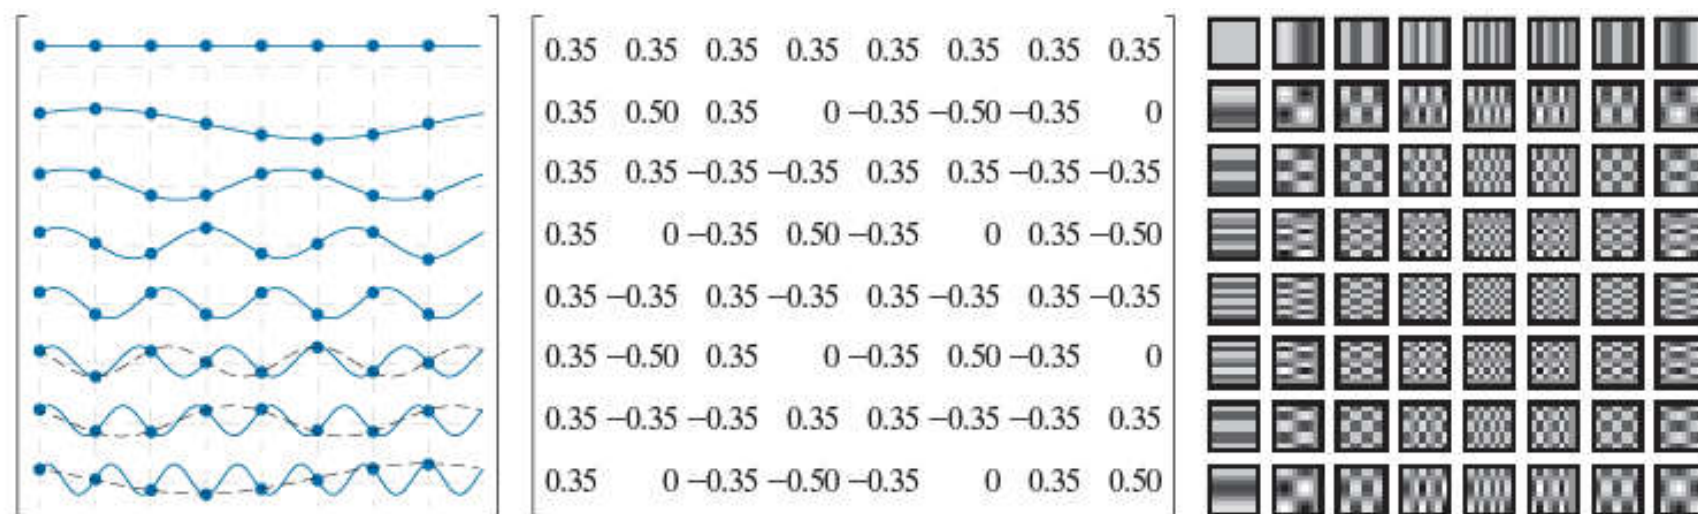
实函数的傅里叶变换是复值的

$$A_{HY} = A_{HY}^T = A_{HY}^{-1}$$

可用于正反变换

## 四、傅里叶相关的变换

### ➤ 离散哈特利变换



N=8时离散哈特利变换的变换矩阵和基图像

## 四、傅里叶相关的变换

### ➤ 离散哈特利变换

离散哈特利变换DHT反变换核

$$s(x, u) = \frac{1}{\sqrt{N}} \text{cas}\left(\frac{2\pi ux}{N}\right) = \frac{1}{\sqrt{N}} \left[ \cos\left(\frac{2\pi ux}{N}\right) + \sin\left(\frac{2\pi ux}{N}\right) \right]$$

基于以下等式

$$\text{cas}(\theta) = \sqrt{\frac{2}{N}} \cos(\theta - \pi/4)$$

$$s(x, u) = \sqrt{\frac{2}{N}} \cos\left(\frac{2\pi ux}{N} - \frac{\pi}{4}\right)$$

$$\begin{aligned} A_{HY} &= \text{Real}\{A_F\} - \text{Imag}\{A_F\} \\ &= \text{Real}\{(1 + j)A_F\} \end{aligned}$$

结论：哈特利变换的基函数是以离散傅里叶变换为母小波平移（ $\pi/4$ ）、缩放（ $\sqrt{2}$ ）而来

## 四、傅里叶相关的变换

- 离散哈
- 一个例子:
- 其傅里叶

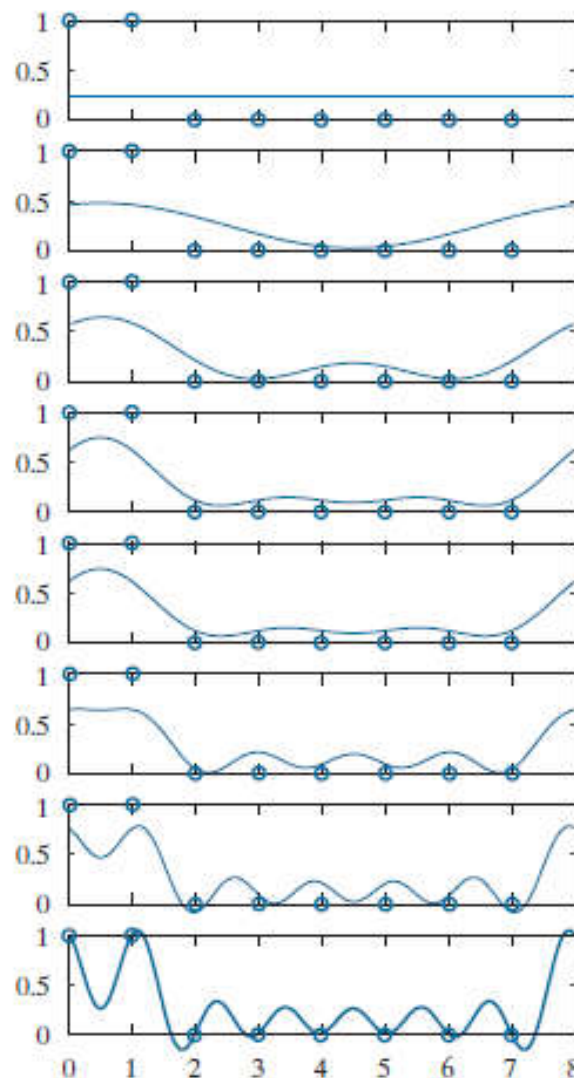
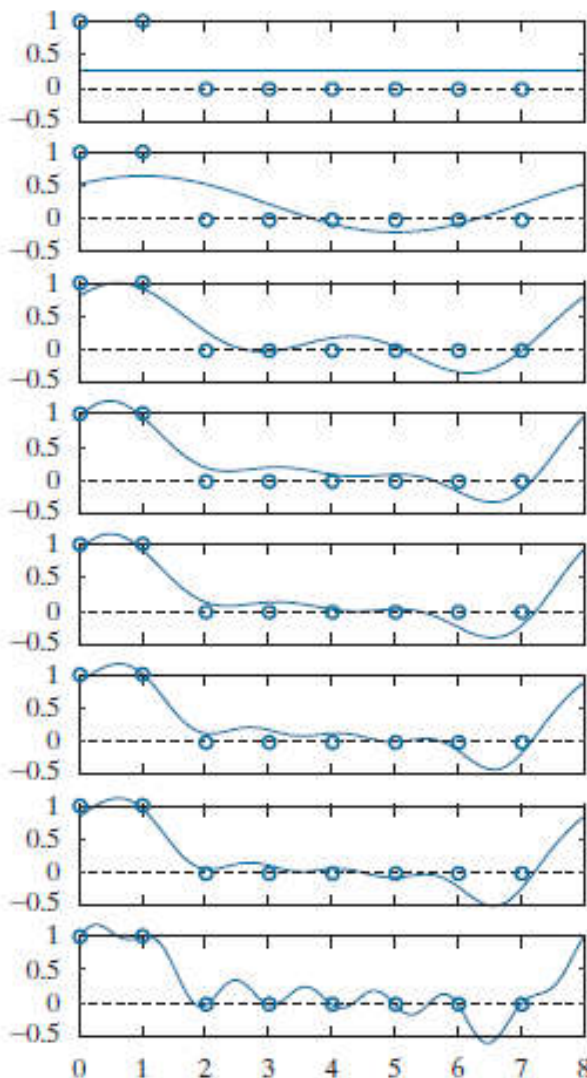
$$t_{Fr} = A_{Fr}f$$

$$t_{Fj} = A_{Fj}f =$$

$$A_{HY} = (A_{Fr} -$$

$$f = A_{HY}^T t_{HY}$$

$$f = [f(0)f(1)f(2)f(3)f(4)f(5)f(6)f(7)]^T$$



$$[5 \ 0.35+j0.35 \ 0.6+j0.25]^T$$

$$\begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 \\ -j & -j\omega & -1 & -\omega & j & j\omega \\ -1 & j & 1 & -j & -1 & j \\ j & \omega & -1 & j\omega & -j & -\omega \\ 1 & -1 & 1 & -1 & 1 & -1 \\ -j & j\omega & -1 & \omega & j & -j\omega \\ -1 & -j & 1 & j & -1 & -j \\ j & -\omega & -1 & -j\omega & -j & \omega \end{bmatrix}$$

3×8酉变换矩阵

赵荣昌

## 四、傅里叶相关的变换


### ➤ 离散余弦变换 (DCT)

$$s(x, u) = \alpha(u) \cos\left(\frac{(2x + 1)u\pi}{2N}\right)$$

$$\alpha(u) = \begin{cases} \sqrt{1/N}, & u = 0 \\ \sqrt{2/N}, & u = 1, 2, \dots, N - 1 \end{cases}$$

DCT

DHT






## 四、傅里叶相关的变换

### ➤ 离散正弦变换 (DST)

DCT

$$s(x, u) = \sqrt{\frac{2}{N+1}} \sin\left(\frac{(x+1)(u+1)\pi}{N+1}\right)$$

DST

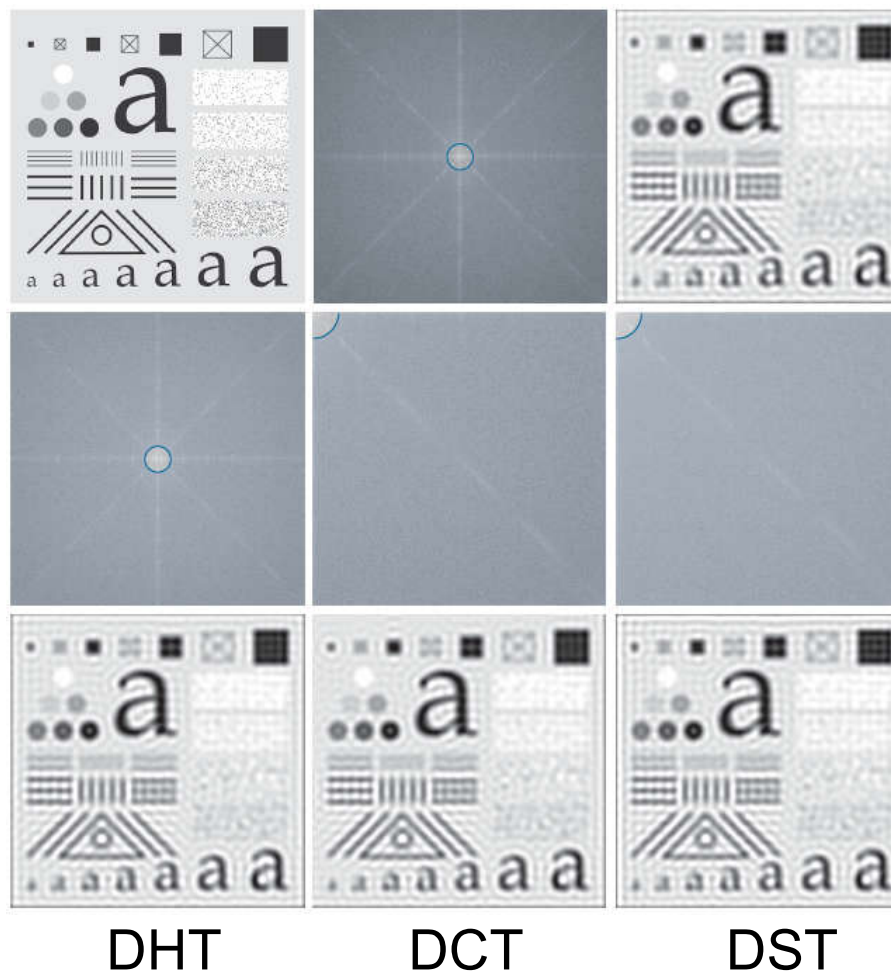


## 四、傅里叶相关的变换

### ➤ 离散正弦变换 (DST)

DFT

理想低通滤波





## 五、图像多分辨率分析

- 图像由相似纹理和灰度级连成的区域组成，形成物体的表示
- 物体较小时，较高的分辨率
- 物体较大时，较低的分辨率
- 若较大和较小同时存在呢？
- 图像金字塔
- 子带编码
- 哈尔变换



## 五、图像多分辨率分析

### ➤ 图像金字塔

以金字塔形状排列的、分辨率逐步降低的图像集合


底部:  $N \times N$

顶点:  $1 \times 1$

第 $i$ 级:  $2^i \times 2^i$

低分辨率

高分率



## 五、图像多分辨率分析



### ➤ 图像金字塔

以金字塔形状排列的、分

底部:  $N \times N$

顶点:  $1 \times 1$

第 $i$ 级:  $2^i \times 2^i$



近似金字塔

预测残差金字塔  
(拉普拉斯金字塔)

## 五、图像多分辨率分析


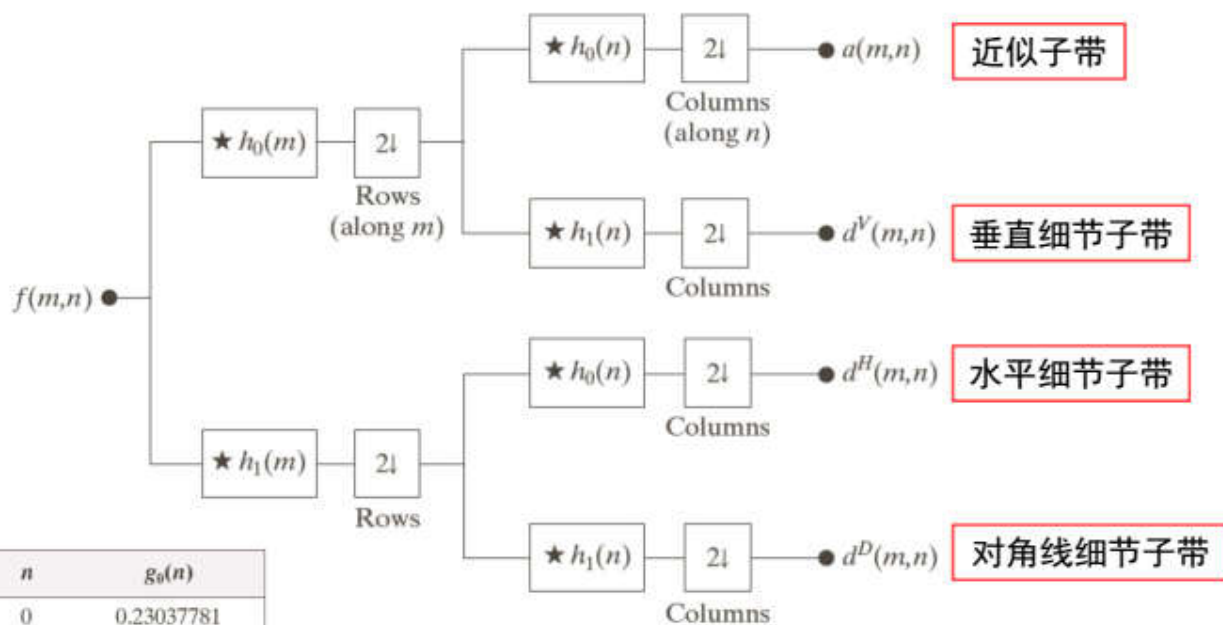
### ➤ 子带编码

一幅图像

• a b

•  $f(n)$

•



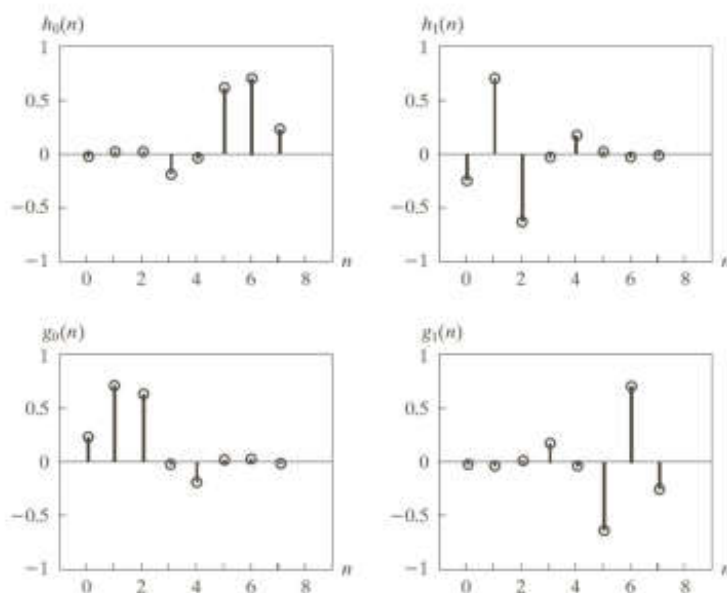
englavender

$n$	$g_0(n)$
0	0.23037781
1	0.71484657
2	0.63088076
3	-0.02798376
4	-0.18703481
5	0.03084138
6	0.03288301
7	-0.01059740


$g_0(n)$ 的Daubechies 8抽头  
归一化正交滤波器系数

## 五、图像多分辨率分析

### ➤ 子带编码



4个8抽头Daubechies归一化  
正交滤波器的冲击响应



子带分离结果，4个子带分别是：  
(a) 近似子带 (b) 水平细节子带  
(c) 垂直细节子带 (d) 对角线细节子带

## 五、图像多分辨率分析

### ➤ 哈尔（Haar）变换

- 一种最古老最简单的正交基函数

$$u = 2^p + q$$

$p$ 是 $u$ 中包含的2的最大次幂， $q$ 是余数

$$h_u(x) = \begin{cases} 1 & u = 0 \text{ 和 } 0 \leq x < 1 \\ 2^{p/2} & u > 0 \text{ 和 } q/2^p \leq x \leq (q + 0.5)/2^p \\ -2^{p/2} & u < 0 \text{ 和 } (q + 0.5)/2^p \leq x \leq (q + 1)/2^p \\ 0 & \text{其他} \end{cases}$$

定义在 $x \in [0,1)$ 上，变量 $u$ 是一个整数，对于 $u > 0$ 时，可以唯一的分解成 $u = 2^p + q$ ;

- 哈尔 变换的矩阵形式

$$T = HFH^T$$

$H$ :  $N \times N$ 哈尔变换矩阵;  $F$ :  $N \times N$ 图像矩阵,  $T$ :  $N \times N$ 变换结果

## 五、图像多分辨率分析

### ➤ 哈尔 (Haar) 变换

- 一种最古老最简单的正交基函数

$$u = 2^p + q$$

$p$ 是 $u$ 中包含的2的最大次幂,  $q$ 是余数

$$h_u(x) = \begin{cases} 1 & u = 0 \text{ 和 } 0 \leq x < 1 \\ 2^{p/2} & u > 0 \text{ 和 } q/2^p \leq x \leq (q + 0.5)/2^p \\ -2^{p/2} & u < 0 \text{ 和 } (q + 0.5)/2^p \leq x \leq (q + 1)/2^p \\ 0 & \text{其他} \end{cases}$$

定义在 $x \in [0,1)$ 上, 变量 $u$ 是一个整数, 对于 $u > 0$ 时, 可以唯一的分解成 $u = 2^p + q$ ;

- 哈尔 变换的矩阵形式

$$T = HFH^T$$

$H$ :  $N \times N$ 哈尔变换矩阵;  $F$ :  $N \times N$ 图像矩阵,  $T$ :  $N \times N$ 变换结果

## 五、图像多分辨率分析

### ➤ 哈尔 (Haar) 变换

- 一种最古老最简单的正交基函数

$$h_u(x) = \begin{cases} 1 & u = 0 \text{ 和 } 0 \leq x < 1 \\ 2^{p/2} & u > 0 \text{ 和 } q/2^p \leq x \leq (q + 0.5)/2^p \\ -2^{p/2} & u < 0 \text{ 和 } (q + 0.5)/2^p \leq x \leq (q + 1)2^p \\ 0 & \text{其他} \end{cases}$$

$$s(x, u) = \frac{1}{\sqrt{N}} h_u(x/N)$$

- 哈尔 矩阵

$$H_N = \begin{bmatrix} h_0(0/N) & h_0(1/N) & \dots & h_0(N-1/N) \\ h_1(0/N) & h_1(1/N) & \dots & h_1(N-1/N) \\ \vdots & \vdots & \ddots & \vdots \\ h_{N-1}(0/N) & h_{N-1}(1/N) & \dots & h_{N-1}(N-1/N) \end{bmatrix} \quad A_N = \frac{1}{\sqrt{N}} H_N$$

$$H_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$


$$H_4 = \frac{1}{\sqrt{4}} \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & -1 & -1 \\ \sqrt{2} & \sqrt{2} & 0 & 0 \\ 0 & 0 & \sqrt{2} & -\sqrt{2} \end{bmatrix}$$



## 五、图像多分辨率分析

### ➤ 哈尔（Haar）变换

- 一种最古老最简单的正交基函数



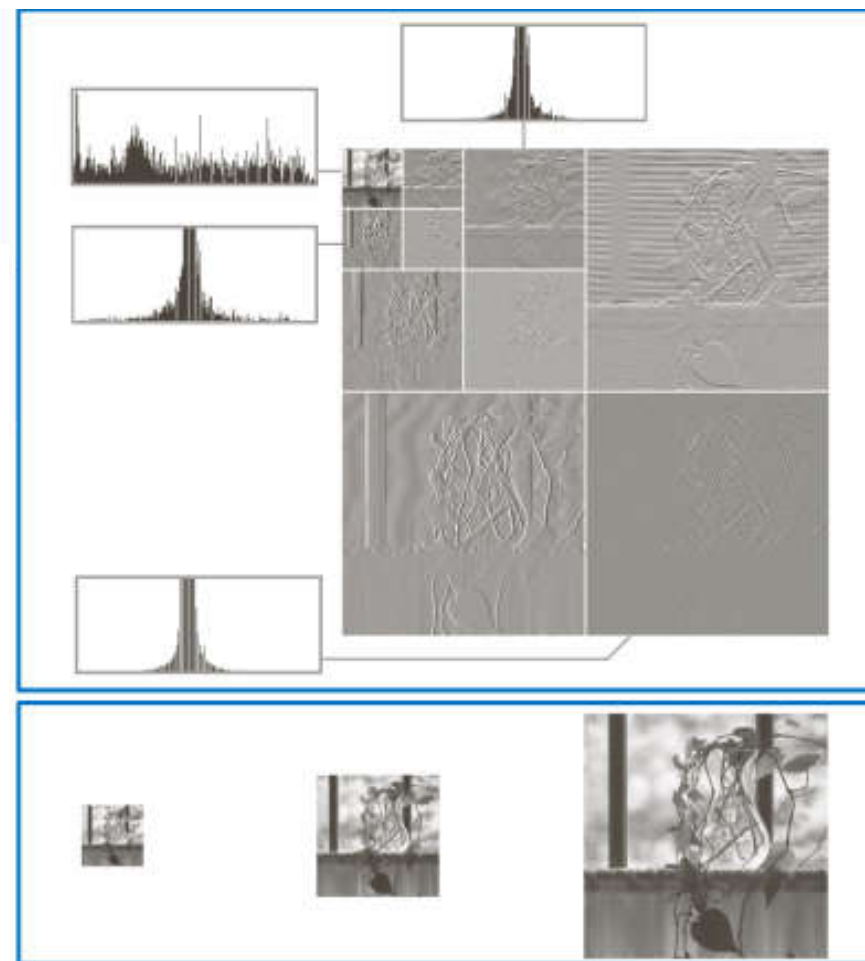
$$H_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

$$H_4 = \frac{1}{\sqrt{4}} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 & 0 \\ 0 & 0 & \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

## 五、图像多分辨率分析

### ➤ 哈尔 (Haar) 变换

$$H_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$



## 五、图像多分辨率分析

### ➤ 多分辨率分析

- 回到前面，定义函数  $\varphi(x)$ ，以它为基础函数，通过整数平移、实数二值尺度、平方可积得到生成一个函数集

$$\varphi_{j,k}(x) = 2^{j/2} \varphi(2^j x - k) \quad \text{—— 尺度函数}$$

把基本函数称为尺度函数

- 例子：哈尔尺度函数

$$\varphi(x) = \begin{cases} 1, & 0 \leq x \leq 1 \\ 0, & \text{其他} \end{cases}$$







## 五、图像多分辨率分析

### ➤ 多分辨率分析

- 回到前面，定义函数  $\varphi(x)$ ，以它为基础函数，通过整数平移、实数二值尺度、

平方可积得到生成一个函数集

$$\varphi_{j,k} = 2^{j/2} \varphi(2^j x - k)$$



固定 $j$ ，张成的函数空间

$$\{\varphi_{0,k} | k \in \mathbb{Z}\} \quad V_0$$

$$\{\varphi_{1,k} | k \in \mathbb{Z}\} \quad V_1$$

增大 $j$ ，增加函数空间的  
可表示的函数的数量，  
允许包含变化细节更多的  
函数

## 五、图像多分辨率分析

### ➤ 多分辨率分析

$$\varphi_{j,k} = 2^{j/2} \varphi(2^j x - k)$$



若  $\varphi(x) \in V_j$ , 则  $\varphi(2x) \in V_{j+1}$







#### ● 例子

$$\varphi(2^0 x) = \sum_{k \in \mathbb{Z}} h_\varphi \sqrt{2} \varphi(2^1 x - k)$$




低尺度函数可以用高尺度函数线性组合表示

$$\dots V_0 \subset V_1 \dots$$



多分辨率分析MRA



属于  $V_1$  但不属于  $V_0$

赵荣昌







## 五、图像多分辨率分析

### ➤ 多分辨率分析


- 回到前面，定义函数  $\varphi(x)$ ，以它为基础函数，通过整数平移、实数二值尺度、

平方可积得到生成一个函数集

$$\varphi_{j,k} = 2^{j/2} \varphi(2^j x - k)$$



多分辨率分析MRA



## 六、小波变换

### ➤ 小波函数

#### ● 定义函数集


$$\psi_{j,k}(x) = 2^{j/2} \psi(2^j x - k)$$

$$\varphi_{j,k} = 2^{j/2} \varphi(2^j x - k) \text{ —— 尺度函数}$$

对于任意的  $j$ ，所有关于  $k$  的函数张成一个子空间  $V_j = \text{span}\{\varphi_{j,k}(x)\}$

增加  $j$  就是增加了  $V_j$  的大小

令  $W_j$  表示由函数  $\{\psi_{j,k} | k \in \mathbb{Z}\}$  张成的函数空间，则有  $V_{j+1} = V_j \oplus W_j$



$V_{j+1}$  中， $V_j$  的正交补集  $W_j$ ，且正交

$$\langle \varphi_{j,k}(x), \psi_{j,l}(x) \rangle = 0, \quad k \neq l$$

## 六、小波变换

### ➤ 小波函数

- 小波空间  $\psi_{j,k}(x) = 2^{j/2} \psi(2^j x - k)$


$$W_{j,k} = \text{span}\{\psi_{j,k} | k \in \mathbb{Z}\}$$

- 尺度空间

$$\varphi_{j,k} = 2^{j/2} \varphi(2^j x - k)$$

$$V_j = \text{span}\{\varphi_{j,k}(x)\}$$

小波空间  $W_j$  位于尺度空间  $V_{j+1}$  内部，所以小波函数可以表示为平移且分辨率加倍后的尺度函数的加权和。



$$\psi(x) = \sum_k h_\psi(k) \sqrt{2} \varphi(2x - k)$$

$$\psi_{j,k}(x) \in W_j \subset V_{j+1}$$

$V_{j+1}$  中， $V_j$  的正交补集  $W_j$ ，且正交

$$\langle \varphi_{j,k}(x), \psi_{j,l}(x) \rangle = 0, \quad k \neq l$$




## 六、小波变换

### ➤ 小波函数

小波空间 $W_j$ 位于尺度空间 $V_{j+1}$ 内部，所以小波函数可以表示为平移且分辨率加倍后的尺度函数的加权和。

$$\psi(x) = \sum_k h_\psi(k) \sqrt{2} \phi(2x - k) \quad h_\psi(k) = (-1)^k h_\phi(1 - k)$$

小波函数系数









$$\psi_{j,k}(x) \in W_j \subset V_{j+1}$$

$V_{j+1}$ 中， $V_j$ 的正交补集 $W_j$ ，且正交

$$\langle \phi_{j,k}(x), \psi_{j,l}(x) \rangle = 0, \quad k \neq l$$

## 六、小波变换

### ➤ 哈尔小波



## 六、小波变换

### ➤ 小波级数展开

将函数 $f(x)$ 展开为小波函数和尺度函数的小波级数

$$f(x) = \sum_k c_{j_0}(k) \varphi_{j_0,k}(x) + \sum_{j=j_0}^{\infty} \sum_k d_j(k) \psi_{j,k}(x)$$

近似系数

细节系数

$$c_{j_0}(k) = \langle f(x), \varphi_{j_0,k}(x) \rangle$$

$$d_j(k) = \langle f(x), \psi_{j,k}(x) \rangle$$

## 六、小波变换

### ➤ 小波级数展开

将函数 $f(x)$ 展开为小波函数和尺度函数的小波级数

$$y = \begin{cases} x^2, & 0 \leq x \leq 1 \\ 0, & \text{其他} \end{cases}$$







$$c_0(0) = \int_0^1 x^2 \varphi_{0,0}(x) dx$$

$$= \int_0^1 x^2 dx = \frac{1}{3}$$

$$d_0(0) = \int_0^1 x^2 \psi_{0,0}(x) dx$$

$$= \int_0^{0.5} x^2 dx - \int_{0.5}^1 x^2 dx = -\frac{1}{4}$$

... ..



## 六、小波变换

### ➤ 一维离散小波变换

如果待展开的函数是离散的，得到的系数就称为离散小波变换（DWT）

$$f(x) = \frac{1}{\sqrt{N}} \left[ T_{\varphi}(0,0)\varphi(x) + \sum_{j=0}^{J-1} \sum_{k=0}^{2^j-1} T_{\psi}(j,k)\psi_{j,k}(x) \right]$$

$$T_{\varphi}(0,0) = \langle f(x), \varphi_{0,0}(x) \rangle = \langle f(x), \varphi(x) \rangle = \frac{1}{\sqrt{N}} \sum_{x=0}^{N-1} f(x)\varphi^*(x)$$

$$T_{\psi}(j,k) = \langle f(x), \psi_{j,k}(x) \rangle = \frac{1}{\sqrt{N}} \sum_{x=0}^{N-1} f(x)\psi_{j,k}^*(x)$$

## 六、小波变换

### ➤ 二维离散小波变换

在二维情况下，需要1个二维尺度函数 $\varphi(x, y)$ 和3个二维小波 $\psi^H(x, y)$ ,  $\psi^V(x, y)$ ,  $\psi^D(x, y)$ , 并且满足可分离的尺度函数

$$\varphi(x, y) = \varphi(x)\varphi(y)$$

可分离的方向敏感小波

$$\psi^H(x, y) = \psi(x)\varphi(y)$$

水平方向

$$\psi^V(x, y) = \varphi(x)\psi(y)$$

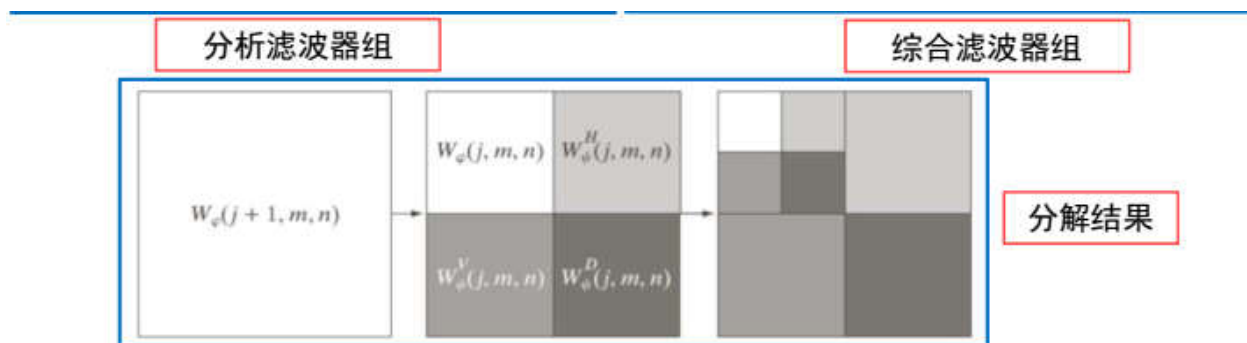
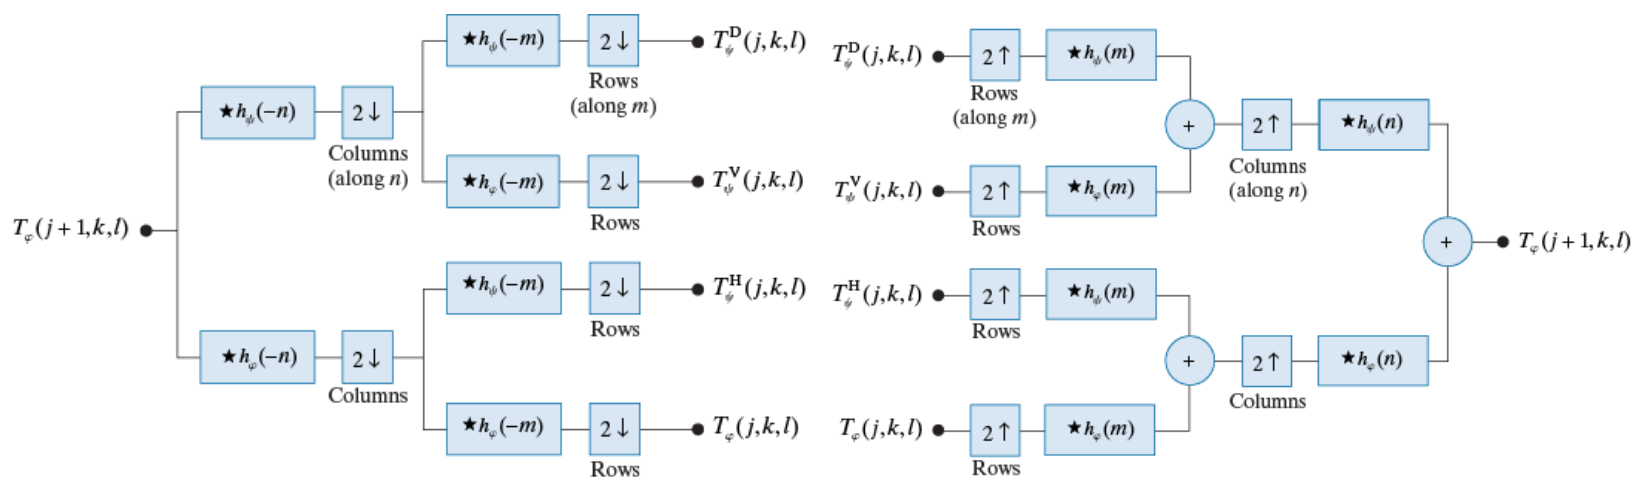
垂直方向

$$\psi^D(x, y) = \psi(x)\psi(y)$$

对角线方向


## 六、小波变换

### ➤ 二维离散小波变换



## 六、小波变换

### ➤ 二维离散小波

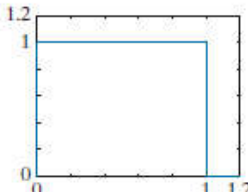
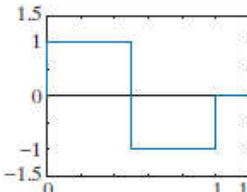
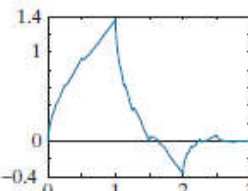
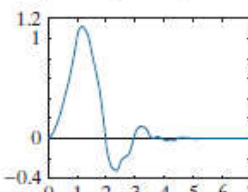
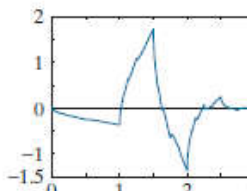
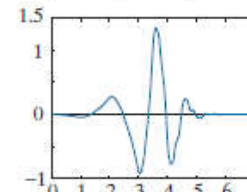




## 六、小波变换


### ➤ 二维离散小波变换

**TABLE 6.1**  
Some representative wavelets.

Wavelet Name or Family	Scaling Function	Wavelet Function	Filter Coefficients
<b>Haar</b> The oldest and simplest wavelets. Orthogonal and discontinuous.			$g_0(n) = \{1/\sqrt{2}, 1/\sqrt{2}\}$
<b>Daubechies family</b> Orthogonal with the most vanishing moments for a given support. Denoted dbN, where N is the number of vanishing moments; db2 and db4 shown; db1 is the Haar of the previous row.	 	 	$g_0(n) = \{0.482963, 0.836516, 0.224144, -0.129410\}$ $g_0(n) = \{0.230372, 0.714847, 0.630881, -0.027984, -0.187035, 0.030841, 0.032883, -0.010597\}$

#### Symlet family


Orthogonal with the least asymmetry and most vanishing moments for a given support (sym4 or 4th order shown).



$$g_0(n) = \{0.032231, -0.012604, -0.099220, 0.297858, 0.803739, 0.497619, -0.029636, -0.075766\}$$

#### Cohen-Daubechies-Feauveau 9/7

Biorthogonal B-spline used in the irreversible JPEG2000 compression standard (see Chapter 8).

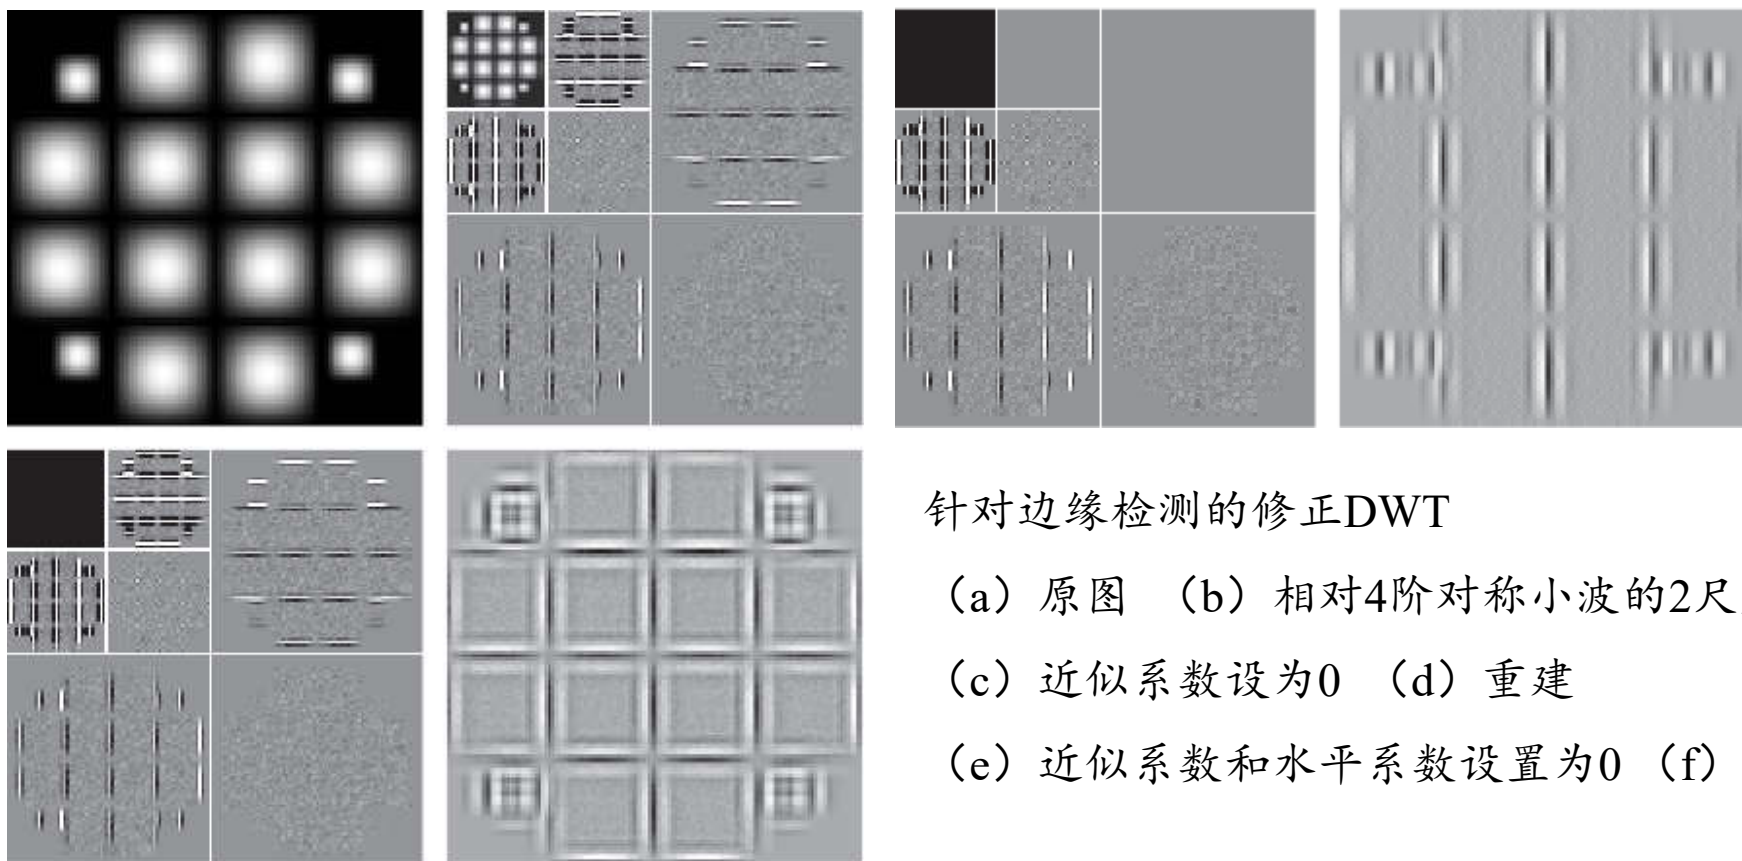


$$h_0(n) = \{0.026749, -0.016864, -0.078223, 0.266864, 0.602949, 0.266864, -0.078223, -0.016864, 0.026749\}$$

$$h_1(n) = \{-0.091271, -0.057544, 0.591272, -1.115087, 0.591272, 0.057544, -0.091271, 0\}$$

## 六、小波变换

### ➤ 二维离散小波变换



针对边缘检测的修正DWT



(a) 原图 (b) 相对4阶对称小波的2尺度DWT

(c) 近似系数设为0 (d) 重建

(e) 近似系数和水平系数设置为0 (f) 重建

## 六、小波变换

### ➤ 应用



**Thanks! 😊**

**Any Question?**